

TRABAJO FIN DE GRADO
PARTE ANÁLISIS DEL DATO

Alumno: Álvaro Paterman Sotillo

Email: alvapatersoti@gmail.com

Doble grado en Business Analytics y administración y dirección de empresas

Curso académico 2025-2026

Índice de Contenidos

ANÁLISIS DEL DATO

1. Marco teórico de la metodología analítica

- 1.1 Modelo A: K-Means Clustering
- 1.2 Modelo B: Random Forest
- 1.3 Modelo C: Gradient Boosting
- 1.4 Las métricas de evaluación que he usado y por qué

2. Preparación del Dataset para el modelado

- 2.1 Qué variables incluyo como predictores y por qué
- 2.2 Cómo divido el dataset en entrenamiento y test

3. Implementación y resultados de los modelos predictivos

- 3.1 Modelo A: K-Means Clustering
- 3.2 Modelo B: Random Forest
- 3.3 Modelo C: Gradient Boosting (el modelo elegido)
- 3.4 Comparativa global de los tres modelos

4. Análisis de importancia de variables e interpretación

- 4.1 Qué variables determinan más la demanda
- 4.2 Análisis de residuos del modelo final
- 4.3 Curvas de aprendizaje: diagnóstico del overfitting

5. Modelo predictivo horario: Análisis complementario

- 5.1 Por qué construí también un modelo horario
- 5.2 Resultados del modelo horario

6. Síntesis y conclusiones técnicas

- 6.1 La jerarquía de factores que determinan la demanda
- 6.2 Limitaciones del análisis que reconozco

7. Bibliografía en formato APA.

1. Marco Teórico de la Metodología Analítica

1.1 Modelo A: K-Means Clustering – qué hace y por qué lo uso

El K-Means es un algoritmo de clustering no supervisado que agrupa las 731 observaciones del dataset en k grupos (clústers), intentando que los días dentro de cada grupo sean lo más similares posible entre sí y lo más diferentes posible de los otros grupos.

El algoritmo funciona en dos pasos que se repiten hasta que no hay más cambios: primero asigna cada observación al centroide más cercano y luego recalcula cada centroide como la media de todas las observaciones de su grupo. Para elegir el número de clústeres (k), usé dos métodos donde uno en el que se muestra un cambio de pendiente en la curva de inercia alrededor de $k=4$, y otro en el que también alcanza un valor aceptable para $k=4$.

Que el número óptimo sea $k=4$ no es casualidad: coincide exactamente con las cuatro estaciones del año, lo que refuerza la validez del resultado. Este modelo no predice la demanda exacta de un día concreto, sino que clasifica los días en perfiles de demanda (por ejemplo, "días fríos de invierno con baja demanda", "días calurosos de verano con alta demanda"...).

Algo importante que tuve en cuenta es que antes de aplicar K-Means estandaricé todas las variables. Esto es obligatorio porque el K-Means usa distancias euclídeas y, si no hubiese estandarizado, las variables con escalas más grandes dominarían artificialmente el agrupamiento.

1.2 Modelo B: Random Forest

El Random Forest es un método de ensemble que construye un gran número de árboles de decisión de forma independiente y combina sus predicciones tomando la media. La clave de su éxito es que introduce dos tipos de aleatoriedad que hacen que los árboles sean distintos entre sí y, al promediarlos, la varianza del conjunto sea mucho menor que la de un único árbol:

- Bagging : cada árbol se entrena sobre una muestra aleatoria con reemplazamiento del dataset de entrenamiento. Esto significa que cada árbol ve aproximadamente el 63% de los datos originales y aprende patrones ligeramente distintos.
- Selección aleatoria de variables: Esto introduce diversidad entre los árboles y evita que todos sigan la misma lógica de división.

Una ventaja adicional del Random Forest que me resultó muy útil es que proporciona de forma automática una estimación de la importancia de cada variable, calculada como la reducción media

de impureza (varianza en regresión) que produce cada variable en todos los nodos de todos los árboles donde se usó. Esto me permite saber cuáles son las variables que más determinan la demanda.

1.3 Modelo C: Gradient Boosting – el modelo que mejor funciona

El Gradient Boosting es también un método de ensemble, pero a diferencia del Random Forest construye los árboles de forma secuencial en lugar de paralela. La idea es que cada nuevo árbol se centra en corregir los errores que cometió el modelo anterior. La principal diferencia frente al Random Forest es que los árboles del Gradient Boosting son más sencillos individualmente (max_depth=5 frente a max_depth=12), pero al acumularse secuencialmente muchos de ellos consiguen modelar relaciones muy complejas. Esta combinación de árboles simples iterativos tiende a dar mejores resultados que el promedio de árboles complejos independientes, especialmente en datos estructurados como estos.

1.4 Las métricas de evaluación que he usado y por qué

Para comparar los modelos de forma rigurosa usé cuatro métricas complementarias, cada una de las cuales ilumina un aspecto diferente del rendimiento:

Métrica	Fórmula	Rango	Qué mide	Sensibilidad a errores grandes
MAE	$(1/n) \times \sum y_i - \hat{y}_i $	$[0, +\infty)$	Error medio en alquileres/día; directamente interpretable	Baja: pondera todos los errores por igual
RMSE	$\sqrt{[(1/n) \times \sum (y_i - \hat{y}_i)^2]}$	$[0, +\infty)$	Error típico de predicción; $RMSE \geq MAE$ siempre. La diferencia $RMSE - MAE$ indica si hay errores grandes	Alta: penaliza cuadráticamente los errores grandes
R^2	$1 - SS_{res} / SS_{tot}$	$(-\infty, 1]$	Proporción de varianza de cnt explicada por el modelo. $R^2=1$ es perfecto;	Baja: está normalizado por la varianza total

			$R^2=0$ equivale a predecir siempre la media	
CV R^2 (5-Fold)	Media de R^2 en 5 folds	$(-\infty, 1]$	Estimación más fiable del R^2 sobre datos no vistos. Detecta overfitting si $CV R^2 \ll R^2 \text{ test}$	Baja: se promedia sobre 5 particiones distintas

La validación cruzada de 5 pliegues divide el dataset en 5 partes iguales y entrena y evalúa el modelo 5 veces, usando en cada vuelta una parte diferente como test y el resto como entrenamiento. El CV R^2 final es la media de los 5 valores obtenidos. La ventaja principal es que da una estimación más fiable del rendimiento real del modelo porque usa todos los datos tanto para entrenar como para evaluar, aunque nunca al mismo tiempo.

La diferencia entre el R^2 de test y el CV R^2 es el principal indicador de overfitting: si el R^2 de test es mucho más alto que el CV R^2 , el modelo ha memorizado el conjunto de test. En este trabajo los valores son muy similares en todos los modelos, lo que me indica que no hay problemas de overfitting significativos.

2. Preparación del Dataset para el Modelado

2.1 Qué variables incluyo como predictores y por qué

La selección de las 11 variables predictoras fue una de las decisiones más importantes del proceso de modelado. La hice siguiendo tres criterios: que la variable tenga una correlación estadísticamente significativa con la demanda, que haya una razón causal lógica que explique por qué esa variable debería influir en la demanda, y que no introduzca fuga de información, es decir, que sea una variable que en la realidad se conocería antes del momento en que se quiere hacer la predicción.

Variable	Tipo	Por qué la incluyo	Correlación con cnt
season	Categórica ordinal	Captura la estacionalidad astronómica; $r=0,41$ con cnt	0,406
yr	Binaria	Captura la tendencia de crecimiento interanual (+64,4%)	0,567
mnth	Numérica discreta	Resolución mensual que complementa a season	0,280
holiday	Binaria	Diferencia festivos de laborables no festivos	0,030 (baja pero conceptualmente importante)
weekday	Numérica discreta	Captura el patrón semanal vs ocio	0,067
workingday	Binaria	Combina holiday y weekday en un único indicador	0,061
weathersit	Ordinal	Proxy de condiciones adversas (lluvia, nieve)	-0,298
temp	Continua	Principal factor climático; $r=0,627$ con cnt	0,627
atemp	Continua	Percepción subjetiva; $r=0,631$, ligeramente superior a temp	0,631
hum	Continua	Efecto negativo moderado; $r=-0,101$	-0,101
windspeed	Continua	Efecto disuasor; $r=-0,235$	-0,235

2.2 Cómo divido el dataset en entrenamiento y test

Divido el dataset de 731 observaciones en 80% para entrenamiento (584 días) y 20% para test (147 días), usando `train_test_split` con `random_state=42` para que los resultados sean reproducibles. Elegí hacer la partición aleatoria porque una vez que se controlan los efectos estacionales, los días no tienen una dependencia serial fuerte entre sí.

Conjunto	N registros	Porcentaje	Media cnt	Desv. típica cnt	Distribución temporal
Entrenamiento	584	80%	4.484 alquileres/día	1.944	Distribuida aleatoriamente entre 2011 y 2012
Test	147	20%	4.575 alquileres/día	1.919	Distribuida aleatoriamente entre 2011 y 2012
Total	731	100%	4.504 alquileres/día	1.937	2011-01-01 a 2012-12-31

3. Implementación y Resultados de los Modelos Predictivos

3.1 Modelo A: K-Means Clustering

Para el K-Means, apliqué el algoritmo sobre las 11 variables estandarizadas con $k=4$ clústeres, seleccionado a través del método del codo y el Silhouette Score. Los resultados del ajuste fueron los siguientes:

Métrica de clustering	Valor	Qué indica
Silhouette Score	0,312	Separación moderada-buena entre clústeres; rango [-1,1], un valor $>0,25$ ya es aceptable
Davies-Bouldin Index	(ver notebook)	Cuanto menor, mejor separación entre grupos

Inercia (WCSS)	(ver notebook)	Suma de distancias al cuadrado dentro de cada clúster
Número de clústeres	4	Coincide con las cuatro estaciones del año, lo que valida el resultado

K-Means Clustering (k=4): Selección y Caracterización de Clústeres




Imagen 1. K-Means ($k=4$): vemos los centroides de los clústeres, distribución de demanda por grupo y proyección de los días en el espacio temperatura-demanda coloreada por clúster.

Los cuatro clústeres identificados corresponden de forma bastante clara a cuatro perfiles estacionales de demanda: días de invierno con baja temperatura y baja demanda, días de primavera y otoño con demanda media, días de verano con alta temperatura y alta demanda, y un cuarto grupo de días con condiciones adversas (lluvia, viento fuerte) que tienen baja demanda independientemente de la estación.

3.2 Modelo B: Random Forest

El Random Forest (200 árboles, $\text{max_depth}=12$, $\text{min_samples_leaf}=2$) como primer modelo supervisado me permite predecir la demanda diaria exacta, complementando al K-Means que solo clasifica. Los resultados en el conjunto de test fueron:

Métrica	Valor	Interpretación práctica
MAE	434,6 alquileres/día	El modelo se equivoca en media ± 435 alquileres; un 9,7% de la media diaria
RMSE	689,9 alquileres/día	Error típico; el $RMSE > MAE$ indica que hay algunos días con errores más grandes
R^2 (Test)	0,881	El modelo explica el 88,1% de la varianza de la demanda en datos no vistos
CV R^2 (5-Fold)	$0,870 \pm 0,034$	En validación cruzada el R^2 es 0,870; el gap de 0,011 indica sin overfitting relevante

3.3 Modelo C: Gradient Boosting (el modelo elegido)

El Gradient Boosting (200 árboles, $\text{max_depth}=5$, $\text{learning_rate}=0,05$) obtuvo las mejores métricas en todas las dimensiones evaluadas:

Métrica	Valor	Comparación con Random Forest
MAE	429,5 alquileres/día	-1,2% de error respecto al RF; mejora pequeña pero consistente
RMSE	640,9 alquileres/día	-7,1% respecto al RF; mayor reducción en errores grandes
R^2 (Test)	0,898	El modelo explica el 89,8% de la varianza; +1,7 puntos sobre RF
CV R^2 (5-Fold)	$0,875 \pm 0,028$	Mejor generalización y menor variabilidad entre folds que RF
Gap test – CV R^2	0,023	Pequeño gap confirma que no hay overfitting; el modelo generaliza bien

El MAE de 429,5 alquileres por día significa que, en promedio, el modelo predice la demanda con un error del 9,5% sobre la media. En términos operativos, si un sistema tiene 40 estaciones con una media de 45 alquileres diarios cada una, el error de ± 429 alquileres equivale a equivocarse en unos 10 alquileres por estación, lo que es perfectamente manejable para la planificación. Este nivel de precisión es muy difícil de superar por lo que considero que es el modelo más adecuado.




Imagen 2. Comparativa de los modelos supervisados: dispersión de valores reales vs. predichos para Random Forest (izquierda) y Gradient Boosting (derecha). La mayor concentración de puntos en torno a la diagonal en el Gradient Boosting confirma su superioridad.

3.4 Comparativa global de los tres modelos




Imagen 3. Comparativa visual de las métricas principales entre Random Forest y Gradient Boosting.

	K-Means (no supervisado)	Random Forest	Gradient Boosting ★	Mejor
MAE	Silhouette = 0,312	434,6	429,5	Gradient Boosting
RMSE	—	689,9	640,9	Gradient Boosting
R ² Test	—	0,881	0,898	Gradient Boosting
CV R ²	—	0,870	0,875	Gradient Boosting
Variabilidad CV	—	± 0,034	± 0,028	Gradient Boosting
Interpretabilidad	Alta (perfiles intuitivos)	Media	Media	K-Means
Coste computacional	Muy bajo	Medio	Medio	K-Means
Captura no linealidades	No	Sí	Sí	RF / GB
Robusto a outliers	Sí	Sí	Medio	RF / GB

4. Análisis de Importancia de Variables e Interpretación

4.1 Qué variables determinan más la demanda




Imagen 4. Importancia de variables para Random Forest y Gradient Boosting..

Variable	Importancia RF	Importancia GB	Media RF-GB	Posición en el ranking
temp (Temperatura)	35,4%	39,7%	37,6%	1º en ambos modelos
yr (Año)	28,6%	28,6%	28,6%	2º en ambos modelos
atemp (Sensación térmica)	15,1%	10,8%	13,0%	3º en ambos modelos
hum (Humedad)	5,7%	5,7%	5,7%	4º en ambos modelos
season (Estación)	5,6%	4,5%	5,0%	5º en ambos modelos

windspeed (Viento)	3,0%	3,2%	3,1%	6º en ambos modelos
mnth (Mes)	2,8%	2,6%	2,7%	7º en ambos modelos
weathersit (Meteorología)	1,6%	2,6%	2,1%	8º-7º dependiendo del modelo
weekday (Día semana)	1,6%	1,4%	1,5%	9º en ambos modelos
workingday (Laborable)	0,5%	0,5%	0,5%	10º en ambos modelos
holiday (Festivo)	0,1%	0,5%	0,3%	11º-10º dependiendo del modelo

El resultado que más me sorprendió es que el año sea la segunda variable más importante con el 28,6% de importancia. Al principio pensé que los factores climáticos dominarían completamente, pero tiene mucho sentido ya que el crecimiento del 64,4% de un año a otro es una señal muy fuerte que el modelo captura claramente a través de esta variable.

La temperatura (temp) y la sensación térmica (atemp) juntas acumulan el 50,6% de la importancia en el Gradient Boosting, confirmando que el clima es el factor más determinante de la demanda diaria. En cambio, las variables de tipo de día (weekday, workingday, holiday) acumulan apenas el 2,4%. Esto no significa que el día de la semana no importe, sino que su efecto se expresa principalmente en la distribución horaria (cuándo se usan las bicicletas a lo largo del día) más que en el volumen total diario.

4.2 Análisis de residuos del modelo final




Imagen 5. Análisis de residuos del Gradient Boosting: dispersión de residuos vs. valores predichos (izquierda) y distribución de frecuencias con ajuste normal (derecha).




Imagen 6. Comparativa de valores reales vs. predichos sobre el conjunto de test.

Estadístico de los residuos	Valor	Qué me indica
Media de los residuos	-24,5 alquileres/día	Muy próxima a cero; no hay sesgo sistemático relevante en las predicciones
Desviación típica	640,4 alquileres/día	Equivale al RMSE (confirmación de que la implementación es correcta)

Rango de residuos	$[-1.872, +2.207]$	Los errores más grandes se dan en días atípicos con eventos no capturados en el dataset
% de predicciones con error < 500	57,1%	Más de la mitad de las predicciones tienen un error menor que 500 alquileres
% de predicciones con error < 1.000	78,2%	La gran mayoría de las predicciones son manejables operativamente
Test de Shapiro-Wilk (normalidad)	$W=0,897, p<0,001$	Los residuos no son perfectamente normales, pero esto no invalida MAE ni RMSE

La no normalidad de los residuos es bastante habitual en modelos de ensemble sobre datos del mundo real y no invalida las métricas de evaluación que he usado, porque MAE y RMSE no asumen ninguna distribución en particular. Los errores más grandes (por encima de 1.500 alquileres) corresponden a días con eventos especiales que no están capturados en ninguna de las variables del dataset: nevadas excepcionales, eventos deportivos masivos, cierres de transporte público, etc.

4.3 Curvas de aprendizaje: diagnóstico del overfitting




Imagen 7. Curvas de aprendizaje para Random Forest y Gradient Boosting

Las curvas de aprendizaje son una herramienta muy útil para entender si un modelo tiene problemas de overfitting o de underfitting. Lo que muestra cada modelo es:

- K-Means: al ser un modelo de clustering no supervisado, no aplican curvas de aprendizaje supervisadas.
- Random Forest: el R^2 de entrenamiento es muy alto ($\sim 0,99$), lo que indica cierto overfitting.
- Gradient Boosting: tiene un gap train-val menor (train $\sim 0,92$, val $\sim 0,88$), lo que confirma que el `learning_rate` bajo (0,05) hace que el modelo sea más resistente al overfitting.

5. Modelo predictivo horario: análisis complementario

5.1 Por qué construí también un modelo horario

Además del modelo diario sobre `day.csv`, he decidido construir un modelo predictivo sobre los datos horarios (`hour.csv`) porque tiene una aplicabilidad operativa directa que el modelo diario no puede ofrecer. Predecir la demanda hora a hora permite planificar la reposición de bicicletas entre estaciones con una antelación de 2 a 4 horas, reduciendo los episodios de saturación o desabastecimiento que son el principal problema de estos sistemas.

El modelo horario usa exactamente la misma técnica que el diario (Gradient boosting con los mismos hiperparámetros) pero añade la variable `hr` (hora del día, de 0h a 23h) como predictor adicional, pasando de 11 a 12 variables.

5.2 Resultados del modelo horario




Figura 18. Modelo horario (Gradient Boosting sobre hour.csv)

Métrica	Modelo diario (day.csv)	Modelo horario (hour.csv)	Comparativa
MAE	429,5 alquileres/día	28,7 alquileres/hora	El modelo horario es más preciso en términos relativos (MAPE ~15%)
RMSE	640,9 alquileres/día	44,8 alquileres/hora	Mayor precisión relativa en el modelo horario
R ² Test	0,898	0,937	El R ² horario supera al diario gracias a la variable hr
Variable más importante	Temperatura (39,7%)	Hora del día (>45%)	En el horario, la hora domina sobre las variables climáticas

El hecho de que el modelo horario tenga un R² mayor (0,937 vs. 0,898) puede parecer sorprendente a primera vista, porque los datos son más granulares y, en principio, más difíciles de predecir. La explicación a esto está en que la variable hr captura casi perfectamente el patrón que genera la mayor parte de la varianza en los datos horarios. El modelo puede distinguir el pico de las 8h del valle de las 14h y del pico de las 17h con mucha precisión, porque esos patrones son muy consistentes de un día laborable a otro.

6. Síntesis, Conclusiones Técnicas y Líneas Futuras

6.1 La jerarquía de factores que determinan la demanda

El análisis combinado de los modelos predictivos me permite establecer la siguiente jerarquía de determinantes de la demanda de estas bicicletas:

- 1. Temperatura ambiente y sensación térmica (combinadas: 50,6% de importancia en Gradient Boosting): son los factores más determinantes. La relación no es lineal sino cuadrática, con un óptimo alrededor de los 25-27°C, a partir de los cuales la demanda se estabiliza o disminuye levemente.
- 2. Tendencia temporal de crecimiento (yr: 28,6%): refleja el proceso de adopción del sistema por parte de nuevos usuarios y la expansión de la oferta. Es el factor que diferencia el año 2011 del año 2012.
- 4. Condiciones meteorológicas adversas (hum + weathersit + windspeed: 11,5%): el efecto disuasor conjunto de la humedad, el viento y las precipitaciones. Una tormenta puede reducir la demanda hasta un 2,7%.
- 5. Tipo de día (weekday + workingday + holiday: 2,4%): modifica la distribución horaria de la demanda más que el volumen total diario, por lo que su importancia aumenta en el modelo horario.

6.2 Limitaciones del análisis que reconozco

Creo que es importante ser honesto sobre las limitaciones de este trabajo para que los resultados se interpreten correctamente:

- Falta de variables de oferta: el dataset no incluye el número de estaciones operativas ni la flota disponible en cada momento. Esto significa que la demanda que mido es la demanda "satisfecha", que puede estar por debajo de la demanda real en los períodos de mayor uso.
- Falta de variables socioeconómicas: no hay datos sobre la densidad de población en las zonas de servicio.
- Eventos especiales no capturados: conciertos, manifestaciones, eventos deportivos o cortes de transporte público generan anomalías en la demanda que no pueden predecirse con las variables disponibles.
- Una única ciudad: las características climáticas y socioeconómicas de Washington D.C. no son idénticas a las de las ciudades europeas, especialmente las mediterráneas (Madrid, Barcelona...).

7. Bibliografía en formato APA

Peña Calderón, L. (2023). *Propuesta para fomentar el uso de la bicicleta como medio de transporte sostenible* [Tesis de grado, Pontificia Universidad Católica del Perú].

Repositorio PUCP. <https://tesis.pucp.edu.pe/items/6e8246de-2326-4a96-81ee-63e499964596>

Franco Pérez, N., Martínez, O., & López, M. (2015). Impacto de la bicicleta pública en la movilidad urbana sostenible. *Revista Ingeniería y Desarrollo*, 33(2), 159–175.

<https://www.sciencedirect.com/science/article/pii/S0121438115000363>

Ríos-Sánchez, J., González, P., & Becerra, C. (2021). Análisis del uso de sistemas de bicicletas compartidas bajo condiciones meteorológicas. *Ingeniería*, 31(4), 121–134.

https://www.scielo.cl/scielo.php?pid=S0718-07642021000400121&script=sci_arttext

Martínez Selva, P. (2022). *La movilidad ciclista y el uso de bicicletas públicas en la ciudad de Valencia* [Trabajo Fin de Máster, Universitat de València]. Roderic.

<https://roderic.uv.es/items/bd5a9ae5-77e5-4d01-9e72-c9b2d2bbf6a5>

García Ruiz, M. (2023). *Integración de la bicicleta pública y el transporte urbano en Santander* [Trabajo Fin de Máster, Universidad de Cantabria]. Repositorio UC.

<https://repositorio.unican.es/xmlui/handle/10902/36942>

Losada-Tascón, A. (2022). *Barreras socioculturales para el uso de bicicletas compartidas en Bogotá* [Tesis de maestría, Pontificia Universidad Javeriana]. Repositorio PUJ.

<https://repositorio.javeriana.edu.co/items/1194b8d8-26a4-4d73-8703-6987716a22bb>

Jiménez Meroño, E. (2023). *Previsión de la demanda en estaciones de bicicletas compartidas mediante aprendizaje automático* [Trabajo Fin de Máster, Universitat Politècnica de València]. Riunet.

<https://riunet.upv.es/entities/publication/fa350745-47ab-4e69-97cf-54b322aa58ed>

Valdivia-Gonzales, A. (2021). *Evaluación del impacto territorial del sistema de bicicletas compartidas en Santiago* [Tesis, Universidad de Chile]. Repositorio UChile.

<https://repositorio.uchile.cl/handle/2250/173212>

Marroquín Flores, D. (2020). *Análisis de movilidad sostenible mediante bicicletas compartidas en Lima Metropolitana* [Trabajo académico, Universidad Peruana de Ciencias

Aplicadas]. Repositorio UPC.

<https://repositorioacademico.upc.edu.pe/handle/10757/652676>

Gandini, A. (2023). Análisis del uso de bicicletas compartidas y su impacto en la movilidad urbana. *Revista del Instituto de Investigaciones Gino Germani*, 5(2), 45–63.

<https://ri.conicet.gov.ar/handle/11336/202149>

Seifert García, R. (2023). *Movilidad urbana sostenible: análisis del sistema de bicicletas compartidas de la ciudad de València* [Tesis, Universitat de València]. Repositorio UV.

<https://producciocientifica.uv.es/documentos/68715254e7607a6ed9f1cdf5>

Pans, M., García-Ferrandis, X., & Llopis, R. (2023). Análisis sociodemográfico del uso del sistema de bicicletas compartidas de València. *Retos*, 51, 96843.

<https://revistaretos.org/index.php/retos/article/view/96843>

IPSOS & Fifteen. (2023). *Bicicleta compartida en España: cifras clave del estudio de referencia*. Fifteen Mobility. <https://fifteen.eu/es/resources/blog/bicicleta-compartida-en-espana-cifras-clave-del-estudio-de-referencia-de-ipsos>

Velasco-Martínez, J. (2023). *Predicción de la demanda en sistemas de bicicletas compartidas mediante series temporales* [Trabajo Fin de Grado, Universitat Politècnica de Catalunya].

UpCommons. <https://upcommons.upc.edu/entities/publication/c644a748-e8c9-4625-8667-915c4f01cfc8>

Sanmiguel-Rodríguez, A. (2023). Barreras e incentivos de la movilidad en un sistema de bicicletas compartidas en un municipio español. *Revista de Estudios Urbanos y Regionales*, 12(1), 1–20.

https://www.researchgate.net/publication/369943849_Barreras_e_incentivos_de_la_movilidad_en_un_sistema_de_bicicletas_compartidas_en_un_municipio_espanol

Anexo: Declaración de uso de inteligencia artificial

De acuerdo con la normativa de la Universidad Francisco de Vitoria para los Trabajos Fin de Grado del curso 2025-26, declaro que me he apoyado en herramientas de Inteligencia Artificial en la elaboración de alguna parte del código y de la memoria.