

TRABAJO FIN DE GRADO
PARTE INGENIERÍA DEL DATO

Alumno: Álvaro Paterman Sotillo

Email: alvapatersoti@gmail.com

Doble grado en Business Analytics y administración y dirección de empresas

Curso académico 2025-2026

Índice de Contenidos

INGENIERÍA DEL DATO

1. Origen y Descripción del Dataset
 - 1.1 Por qué escogí este dataset y qué representa
 - 1.2 Los dos archivos del dataset y qué diferencia hay entre ellos
 - 1.3 Diccionario completo de variables
 - 1.4 Por qué este sistema es comparable a los sistemas europeos
2. Proceso ETL: Extracción, Transformación y Carga
 - 2.1 Fase de Extracción: cómo obtuve los datos
 - 2.1.1 Carga con Python y Pandas
 - 2.1.2 Verificación de que la extracción fue correcta
 - 2.2 Fase de Transformación: limpieza y preparación
 - 2.2.1 Auditoría de calidad de los datos
 - 2.2.2 Transformaciones que apliqué
 - 2.2.3 Variables derivadas para el análisis exploratorio
 - 2.3 Fase de Carga: infraestructura propuesta
 - 2.3.1 Arquitectura de almacenamiento para un sistema en producción
 - 2.3.2 Resumen del flujo ETL implementado
3. Análisis Exploratorio de Datos (EDA)
 - 3.1 Estadísticas descriptivas de la variable objetivo
 - 3.2 Evolución temporal y estacionalidad
 - 3.3 Patrones horarios de demanda
 - 3.4 Impacto de las variables meteorológicas
 - 3.5 Análisis bivariante y matriz de correlaciones
 - 3.6 Tipología de usuarios: esporádicos vs. registrados
4. Bibliografía en formato APA

1. Origen y Descripción del Dataset

1.1 Por qué escogí este dataset y qué representa

Cuando empecé a pensar en el tema del TFG, tenía claro que quería trabajar con datos reales de movilidad urbana. Las bicicletas compartidas me parecían un tema especialmente interesante porque están en plena expansión en Europa y porque generan datos muy ricos que mezclan factores meteorológicos, temporales y de comportamiento social. Después de buscar varias opciones, di con el Bike Sharing Dataset del UCI Machine Learning Repository.

Los datos proceden del sistema Capital Bikeshare de Washington D.C., que lleva operativo desde 2010. Aunque es un sistema americano, sus características son muy similares a los grandes sistemas europeos como BiciMAD en Madrid, Vélib' en París o Call a Bike en Berlín: todos funcionan con estaciones fijas donde se recogen y devuelven las bicicletas, permiten el acceso tanto a usuarios abonados como a usuarios esporádicos, y la demanda depende en gran medida de las condiciones meteorológicas y del momento del día.

Un dato que me llamó mucho la atención al empezar a explorar el dataset es que durante los dos años que cubre (2011 y 2012) el sistema pasó de tener 400 bicicletas y 50 estaciones a tener 1.670 bicicletas y 175 estaciones. Ese crecimiento tan brutal del 64,4% en la demanda es uno de los patrones más llamativos que luego veremos reflejado en los modelos predictivos.

1.2 Los dos archivos del dataset y qué diferencia hay entre ellos.

El dataset viene en dos archivos csv que representan exactamente los mismos datos pero a escalas temporales distintas:

Archivo	Registros	Variables	Granularidad	Para qué sirve principalmente
day.csv	731	16	Datos agrupados por día	Modelado predictivo estratégico y análisis de tendencias
hour.csv	17.379	17	Datos desglosados por hora	Análisis operativo y modelo de gestión hora a hora

El archivo day.csv tiene exactamente 731 filas, que corresponden a los 731 días entre el 1 de enero de 2011 y el 31 de diciembre de 2012, mientras que el archivo hour.csv tiene 17.379 filas.

Para el modelado predictivo principal he usado day.csv porque tiene menos ruido y las variables explican bien la varianza de la demanda a nivel diario. El archivo hour.csv lo he usado para el análisis exploratorio de los patrones horarios y para construir un modelo complementario que permite predecir la demanda hora a hora.

1.3 Diccionario completo de variables

A continuación explico todas las variables del dataset, su tipo estadístico y qué significan en términos reales. Las variables meteorológicas están normalizadas en el dataset original (entre 0 y 1):

Variable	Tipo	Rango / Valores	Valor real	Qué mide
instant	Identificador	1 a 731 / 17.379	—	Número de registro; no se usa como predictor
dteday	Fecha	2011-01-01 a 2012-12-31	—	Fecha del registro; se convierte a datetime
season	Categórica ordinal	1, 2, 3, 4	Invierno, Primavera, Verano, Otoño	Estación astronómica del año
yr	Binaria	0 o 1	2011 o 2012	Captura el crecimiento interanual (+64,4%)
mnth	Entera	1 a 12	Mes del año	Resolución mensual de la estacionalidad
hr	Entera	0 a 23 (solo hour.csv)	Hora del día	Variable más importante en el modelo horario (>45%)
holiday	Binaria	0 o 1	No festivo / Festivo	Diferencia días festivos de laborables no festivos

weekday	Entera	0 a 6	Dom a Sáb	Distingue patrones de commuting vs. ocio
workingday	Binaria	0 o 1	No laborable / Laborable	Combina holiday y weekday en un único indicador
weathersit	Ordinal	1 a 4	Despejado a Tormenta	Condiciones meteorológicas generales del día
temp	Continua	[0,06; 0,86]	$\text{temp} \times 41 = ^\circ\text{C}$ reales	Correlación positiva con cnt ($r = 0,627$)
atemp	Continua	[0,08; 0,84]	$\text{atemp} \times 50 = ^\circ\text{C}$ sensación	Sensación térmica; $r = 0,631$, ligeramente superior a temp
hum	Continua	[0,00; 0,97]	$\text{hum} \times 100 = \%$ humedad	Efecto negativo moderado sobre la demanda ($r = -0,101$)
windspeed	Continua	[0,02; 0,51]	$\text{wind} \times 67 = \text{km/h}$	Efecto disuasor del viento ($r = -0,235$)
casual	Entera	[2; 3.410]	Alquileres/día	Usuarios esporádicos: 18,8% del total, alta variabilidad
registered	Entera	[20; 6.946]	Alquileres/día	Usuarios abonados: 81,2% del total, comportamiento estable
cnt	Entera (TARGET)	[22; 8.714]	Alquileres/día	Variable objetivo: casual + registered

La variable objetivo cnt tiene una media de 4.504 alquileres por día, una desviación típica de 1.937 y un coeficiente de variación del 43%. Este nivel de variabilidad es bastante alto y justifica el uso de modelos más sofisticados que la media simple. La distribución es casi simétrica (asimetría = 0,12) y un poco más plana que la normal, lo que significa que hay bastantes días tanto con demanda muy alta como muy baja.

1.4 Por qué este sistema es comparable a los sistemas europeos

Una pregunta que me hice al empezar el trabajo fue si los resultados de un sistema americano son realmente aplicables al contexto europeo. Después de revisar todo, creo que sí, por tres razones principales. En primer lugar, la estructura básica del servicio es idéntica: estaciones fijas, acceso por abono o por pago puntual, y tarifas similares. Y en segundo lugar, los patrones de uso en días laborables (dos picos de commuting, uno por la mañana y otro por la tarde) se documentan de forma consistente tanto en Capital Bikeshare como en BiciMAD en Madrid o Vélib' en París según los estudios de DeMaio (2009) y del Ayuntamiento de Madrid (2022).

Dicho esto, también reconozco que hay diferencias, por ejemplo el clima mediterráneo de Madrid o Barcelona tiene veranos más extremos que Washington D.C.

2. Proceso ETL: Extracción, Transformación y Carga

2.1 Fase de Extracción: cómo obtuve los datos

2.1.1 Carga con Python y Pandas

Para cargar los datos usé la función `pd.read_csv()` de Pandas, que detecta automáticamente el separador de coma. El único parámetro que añadí manualmente fue la conversión de la columna `dteday` a tipo `datetime64`, que es necesaria para poder hacer agrupaciones temporales y calcular medias móviles.

2.1.2 Verificación de que la extracción fue correcta

Nada más cargar los datos, comprobé que todo cuadraba:

Verificación	Valor esperado (Readme)	Valor obtenido	Resultado
Filas en day.csv	731	731	Correcto
Columnas en day.csv	16	16	Correcto
Filas en hour.csv	17.379	17.379	Correcto
Columnas en hour.csv	17	17	Correcto
Rango de fechas	2011-01-01 a 2012-12-31	2011-01-01 a 2012-12-31	Correcto
Valor máximo de cnt (day)	8.714 (documentado)	8.714	Correcto

2.2 Fase de Transformación: limpieza y preparación

2.2.1 Auditoría de calidad de los datos

Antes de hacer cualquier análisis, lo primero que hice fue revisar la calidad del dataset. Me fijé en cuatro cosas: si había valores que faltaban (nulos), si había filas repetidas (duplicados), si los datos eran coherentes entre sí y si los valores estaban dentro del rango que cabría esperar. Los resultados me sorprendieron bastante gratamente:

Dimensión de calidad	Qué comprobé	day.csv	hour.csv
Compleitud	Valores nulos por columna	0 nulos en 16 columnas	0 nulos en 17 columnas
Unicidad	Filas duplicadas	0 duplicados	0 duplicados

Consistencia interna	cnt = casual + registered	731/731 (100%)	17.379/17.379 (100%)
Validez – season	Valores en {1, 2, 3, 4}	Confirmado	Confirmado
Validez – weathersit	Valores en {1, 2, 3, 4}	1, 2 y 3 detectados (el 4 no aparece en day)	1, 2, 3 y algún 4 en hora muy concreta
Validez – temp	Valores entre 0 y 1	[0,061; 0,862]	[0,020; 1,000]
Validez – hum	Valores entre 0 y 1	[0,000; 0,973]	[0,000; 1,000]
Validez – hr	Valores en {0, ..., 23}	No aplica	0 a 23 confirmado

El hecho de que no haya ningún valor nulo es poco habitual en datos del mundo real. Según la documentación del dataset, los autores ya aplicaron un proceso de limpieza previo a la publicación, que incluyó interpolación lineal para completar los pocos registros meteorológicos que faltaban en las fuentes originales.

2.2.2 Transformaciones que apliqué

Como el dataset ya venía muy limpio, las transformaciones que apliqué fueron básicamente de formato y de interpretabilidad. No tuve que eliminar ninguna fila ni imputar ningún valor:

Transformación	Variable(s)	Tipo original	Tipo resultado	Por qué la apliqué
Conversión a datetime	dteday	Texto (string)	datetime64[ns]	Permite hacer groupby por mes, resample y calcular medias móviles
Desnormalización temperatura	temp	Float [0,1]	Float en °C (×41)	Para interpretar los valores en términos físicos reales
Desnormalización sensación térmica	atemp	Float [0,1]	Float en °C (×50)	Igual que la temperatura; permite

				comparar ambas variables
Desnormalización humedad	hum	Float [0,1]	Float en % ($\times 100$)	Más fácil de interpretar como porcentaje de humedad relativa
Desnormalización viento	windspeed	Float [0,1]	Float en km/h ($\times 67$)	Unidad estándar para el viento, más intuitiva
Mapeo de etiquetas	season, weekday, yr	Entero	Cadena de texto	Solo para los gráficos; los números se mantienen para los modelos
Media móvil 7 días	cnt	Entero	Float	Variable derivada para suavizar la serie temporal y ver la tendencia

2.2.3 Variables derivadas para el análisis exploratorio

Además de las transformaciones de limpieza, creé tres variables adicionales que me ayudaron en el análisis exploratorio. Estas variables no las uso en los modelos predictivos para no introducir problemas de multicolinealidad:

- **cnt_ma7** (media móvil de 7 días de la demanda total): me ayudó a ver la tendencia de crecimiento sin el "ruido" de las variaciones día a día. Lo que se ve es que el crecimiento no fue lineal, sino que se aceleró bastante en la segunda mitad de 2012.
- **prop_casual** (proporción de usuarios esporádicos sobre el total): me permitió estudiar cómo varía el mix de usuarios según la estación y el día de la semana. Los resultados confirman que en verano y los fines de semana hay mucho más peso de los usuarios esporádicos, que son turistas o gente que usa la bici por ocio.
- **temp_bin** (temperatura categorizada en cuartiles): me permitió hacer análisis de varianza (ANOVA) de la demanda por rangos de temperatura, complementando el análisis de correlación lineal con uno no paramétrico.

2.3 Fase de Carga: infraestructura propuesta

2.3.1 Arquitectura de almacenamiento para un sistema en producción

Si este sistema de predicción se implementara en producción en una ciudad europea, yo pensaría en una arquitectura más robusta. La que yo propondría sigue el patrón medallion architecture de tres capas:

- Capa Bronze (datos crudos): los archivos CSV tal y como llegan del sistema de bicicletas, almacenados en un data lake (por ejemplo, Azure Data Lake) sin ninguna modificación. Aquí también llegarían los datos meteorológicos en tiempo real de la API de la AEMET (en el caso de España).
- Capa Silver (datos transformados y validados): los datos pasan por el proceso ETL que he descrito y se almacenan en formato Parquet en Delta Lake, con control de versiones y capacidad de time travel. En esta capa ya estarían limpios, con las variables desnormalizadas y las variables derivadas creadas.
- Capa Gold (datos analíticos listos para modelado): el dataset final en formato tabular, con la selección de features, listo para alimentar los modelos predictivos. En producción, este proceso se actualizaría diariamente con los datos del día anterior.

2.3.2 Resumen del flujo ETL implementado en este TFG

Flujo ETL implementado paso a paso

1. EXTRACCIÓN → UCI Repository → day.csv (731×16) + hour.csv (17.379×17)
2. AUDITORÍA → 0 nulos · 0 duplicados · 100% consistencia interna (cnt = casual + registered)
3. TRANSFORMACIÓN → Conversión datetime · Desnormalización meteorológica · Mapeo de etiquetas · Variables derivadas (cnt_ma7, prop_casual, temp_bin)
4. VALIDACIÓN → Verificación de rangos y tipos tras transformación
5. CARGA → Dataset en memoria RAM (Pandas DataFrame) + exportación a CSV limpio para reproducibilidad · [En producción: Delta Lake con actualizaciones diarias]

3. Análisis Exploratorio de Datos (EDA)

3.1 Estadísticas descriptivas de la variable objetivo

Lo primero que hice antes de hacer ningún gráfico fue calcular los estadísticos básicos de la variable que quiero predecir, cnt. Estos son los resultados:

Estadístico	Valor	Qué significa
N (total de días)	731	El período completo 2011-2012 está completo, sin días que falten
Media (μ)	4.504 alquileres/día	La demanda media diaria del sistema durante esos dos años
Mediana	4.548 alquileres/día	Muy cercana a la media, lo que indica una distribución casi simétrica
Desviación típica (σ)	1.937 alquileres/día	Alta variabilidad: los datos se alejan bastante de la media
Coeficiente de variación	43,0%	Confirma que hay mucha dispersión; un modelo simple no funcionaría bien
Mínimo	22 (17/01/2011)	Día de nevada extrema con -5°C ; casi nadie usó la bicicleta ese día
Máximo	8.714 (15/09/2012)	Sábado con 24°C y cielo despejado; casi el triple de la media invernal
Asimetría	0,12	Prácticamente simétrica; no hay cola larga ni hacia arriba ni hacia abajo
Curtosis	-0,72	Distribución un poco más plana que la normal (platocúrtica)
Total global	3.292.679 alquileres	La actividad total del sistema en los dos años del estudio




Imagen 1. Distribución de la variable objetivo cnt: histograma con media y mediana (izquierda), Q-Q plot de normalidad (centro) y comparativa de los dos años (derecha).

El Q-Q plot me confirmó que la distribución de cnt se aproxima razonablemente a la normal, con ligeras desviaciones en las colas. Esto es una buena noticia para interpretar los residuos del modelo de regresión lineal, aunque los modelos de ensemble que he usado (Random Forest y Gradient Boosting) no necesitan que los datos sigan ninguna distribución en particular.

Un dato que me llamó la atención fue la diferencia entre el día de mayor demanda (8.714 alquileres el 15 de septiembre de 2012, un sábado cálido y soleado de finales de verano) y el de menor demanda (22 alquileres el 17 de enero de 2011, un lunes laborable con nevada y -5°C). La diferencia entre estos dos extremos me da una idea de cuánto varía la demanda del sistema dependiendo de las condiciones.

3.2 Evolución temporal y estacionalidad

Al representar la serie temporal de demanda diaria durante los dos años, se ven claramente tres tipos de variación a distintas escalas temporales, que los modelos predictivos deben ser capaces de capturar:

- Tendencia de largo plazo: el crecimiento del 64,4% de 2011 a 2012, que refleja tanto la expansión física del sistema como el aumento orgánico de usuarios habituales.
- Estacionalidad anual: el ciclo de 12 meses con máximo en verano y mínimo en invierno. La media de julio-agosto (6.351 alquileres/día) casi cuadruplica la de enero-febrero (1.812 alquileres/día).
- Variabilidad semanal: las oscilaciones regulares entre días laborables y fines de semana, que se ven claramente en la serie diaria como pequeñas ondulaciones.

Análisis Exploratorio: Distribución Temporal de la Demanda




Imagen 2. Análisis temporal completo: serie diaria con media móvil de 7 días, demanda media por mes, distribución por estación y comparativa por día de la semana.

Estación	Media diaria	Desv. típica	Mínimo	Máximo	Diferencia respecto a la media global
Invierno	2.604	1.400	22	5.442	-42,2%
Primavera	4.992	1.696	1.000	7.804	+10,8%
Verano	5.644	1.460	2.900	8.714	+25,3%
Otoño	4.728	1.700	1.100	7.836	+5,0%

Algo que me pareció interesante es que la variabilidad dentro de cada estación sigue siendo muy alta: en verano, la demanda oscila entre 2.900 y 8.714 alquileres en un mismo día, una diferencia de 3 veces. Esto me indicó que controlar solo por estación no es suficiente y que hay que incluir también las variables meteorológicas diarias en los modelos.

3.3 Patrones horarios de demanda

Este es uno de los análisis que más me gustó del EDA, porque los datos horarios revelan de forma muy visual cómo se usa el sistema a lo largo del día. Lo primero que salta a la vista al representar la demanda media por hora es que hay dos perfiles radicalmente distintos dependiendo de si es día laborable o no:




Imagen 3. Patrones horarios de demanda: comparativa entre días laborables y festivos/fin de semana y variación por estación del año.

Tipo de día	Pico 1	Hora del pico 1	Pico 2	Hora del pico 2	Patrón observado
Día laborable	477 alquileres/h	8:00 h	525 alquileres/h	17:00 h	Bimodal – uso para ir y volver del trabajo (commuting)
Fin de semana / festivo	373 alquileres/h	13:00 h	—	—	Unimodal – uso más distribuido, orientado al ocio

Me llamó la atención que el pico de las 17:00 h sea un poco más alto que el de las 8:00 h. Creo que tiene lógica: a la mañana hay más presión para llegar puntual al trabajo, así que mucha gente opta por el metro o el autobús, que tienen horarios más fiables. Por la tarde, al salir del trabajo, hay más libertad y la bicicleta es una opción que yo creo que las personas ven muy atractiva para desconectar y hacer algo de ejercicio.

La demanda mínima se produce entre las 2 y las 4 de la madrugada, con medias de entre 8 y 12 alquileres por hora en días laborables. Este es el momento ideal para la reposición de bicicletas entre estaciones, cuando el impacto sobre los usuarios es mínimo.




Imagen 4. Mapa de calor de la demanda media por hora del día y día de la semana. Las dos franjas oscuras horizontales en los días laborables (lunes a viernes) a las 8h y las 17h evidencian el patrón de commuting.

3.4 Impacto de las variables meteorológicas

Las condiciones meteorológicas son el segundo factor más importante que determina la demanda, después de los factores temporales. Calculé la correlación de Pearson entre cada variable meteorológica y la demanda total diaria:

Variable meteorológica	Correlación r de Pearson	p-valor	Qué significa en términos prácticos
Temperatura (°C)	0,627	< 0,001	Es el factor climático más importante: a más temperatura, más alquileres
Sensación térmica (°C)	0,631	< 0,001	Ligeramente superior; los usuarios responden más a cómo sienten el tiempo que al termómetro objetivo

Humedad relativa (%)	$-0,101$	$0,006$	Efecto negativo débil; la humedad alta se asocia a lluvia o calor sofocante
Velocidad del viento (km/h)	$-0,235$	$< 0,001$	Efecto disuasor moderado; el viento fuerte hace que pedalear sea más incómodo y cansado




Imagen 5. Análisis de la relación entre las variables meteorológicas y la demanda diaria.

Un hallazgo que me parece especialmente relevante es que la relación temperatura-demanda no es lineal sino cuadrática: la demanda sube con la temperatura hasta aproximadamente los 25-27°C, a partir de los cuales se estabiliza o incluso baja un poco. Esto tiene mucho sentido: con demasiado calor, la gente prefiere evitar el ejercicio físico.




Figura 6. Impacto de la condición meteorológica general sobre la demanda.

La diferencia entre los días despejados (weathersit=1, media de 4.877 alquileres) y los días con lluvia o nieve (weathersit=3, media de 1.803 alquileres) es de un factor 2,7. Es decir, cuando llueve o nieva la demanda cae a menos de la mitad, lo que tiene implicaciones muy claras para la planificación del servicio.

3.5 Análisis matriz de correlaciones




Imagen 7. Análisis de las principales variables predictoras frente a la demanda total (cnt).




Imagen 8. Matriz de correlación entre las variables numéricas del dataset y distribución de usuarios esporádicos vs. registrados.

La matriz de correlación me reveló dos cosas importantes para el diseño de los modelos. La primera es que temp y atemp tienen una correlación de 0,988 entre sí, lo que indica multicolinealidad severa. Decidí incluir ambas igualmente porque los modelos de ensemble (Random Forest y Gradient Boosting) son robustos a la multicolinealidad, y porque cada variable aporta información ligeramente distinta: una mide la temperatura objetiva y la otra la percepción subjetiva del usuario. La segunda es que la correlación entre registered y cnt es de 0,946, casi perfecta, lo que confirma que los usuarios abonados son los que mueven la mayor parte de la demanda y los que tienen el comportamiento más predecible.

3.6 Tipología de usuarios: esporádicos vs. registrados




Imagen 9. Evolución temporal acumulada de usuarios esporádicos y registrados.

Segmento de usuarios	Total alquileres	% del total	Media diaria	Coef. de variación	Sensibilidad al clima
Usuarios registrados	2.672.662	81,2%	3.656/día	0,37 (variabilidad baja)	Baja: conmutan independientemente del clima en general
Usuarios esporádicos	620.017	18,8%	848/día	0,76 (variabilidad muy alta)	Alta: muy sensibles a la temperatura, lluvia y viento

Total (cnt)	3.292.679	100%	4.504/día	0,43	Combinación de ambos perfiles
-------------	-----------	------	-----------	------	----------------------------------

La diferencia en el coeficiente de variación entre los dos tipos de usuarios (0,37 vs. 0,76) es estadísticamente significativa y tiene implicaciones operativas muy claras. Los usuarios registrados son la "columna vertebral" del sistema: van a trabajar en bicicleta casi independientemente del tiempo, lo que los convierte en la demanda base estable. Los usuarios esporádicos son los que añaden toda la variabilidad estacional y meteorológica: en verano y con buen tiempo su número se dispara, pero ante la mínima lluvia o frío se quedan en casa.

Esto me sugiere una idea para la gestión del sistema: el número mínimo de bicicletas disponibles en cada estación debería calcularse en función de la demanda de usuarios registrados, y añadir capacidad adicional según la previsión meteorológica y estacional para absorber la demanda de usuarios esporádicos.

4. Bibliografía en formato APA

Peña Calderón, L. (2023). *Propuesta para fomentar el uso de la bicicleta como medio de transporte sostenible* [Tesis de grado, Pontificia Universidad Católica del Perú].

Repositorio PUCP. <https://tesis.pucp.edu.pe/items/6e8246de-2326-4a96-81ee-63e49996459>

Franco Pérez, N., Martínez, O., & López, M. (2015). Impacto de la bicicleta pública en la movilidad urbana sostenible. *Revista Ingeniería y Desarrollo*, 33(2), 159–175.

<https://www.sciencedirect.com/science/article/pii/S0121438115000363>

Ríos-Sánchez, J., González, P., & Becerra, C. (2021). Análisis del uso de sistemas de bicicletas compartidas bajo condiciones meteorológicas. *Ingeniería*, 31(4), 121–134.

https://www.scielo.cl/scielo.php?pid=S0718-07642021000400121&script=sci_arttext

Martínez Selva, P. (2022). *La movilidad ciclista y el uso de bicicletas públicas en la ciudad de Valencia* [Trabajo Fin de Máster, Universitat de València]. Roderic.

<https://roderic.uv.es/items/bd5a9ae5-77e5-4d01-9e72-c9b2d2bbf6a5>

García Ruiz, M. (2023). *Integración de la bicicleta pública y el transporte urbano en Santander* [Trabajo Fin de Máster, Universidad de Cantabria]. Repositorio UC.

<https://repositorio.unican.es/xmlui/handle/10902/36942>

Losada-Tascón, A. (2022). *Barreras socioculturales para el uso de bicicletas compartidas en Bogotá* [Tesis de maestría, Pontificia Universidad Javeriana]. Repositorio PUJ.

<https://repository.javeriana.edu.co/items/1194b8d8-26a4-4d73-8703-6987716a22bb>

Jiménez Meroño, E. (2023). *Previsión de la demanda en estaciones de bicicletas compartidas mediante aprendizaje automático* [Trabajo Fin de Máster, Universitat Politècnica de València]. Riunet. <https://riunet.upv.es/entities/publication/fa350745-47ab-4e69-97cf-54b322aa58ed>

Valdivia-Gonzales, A. (2021). *Evaluación del impacto territorial del sistema de bicicletas compartidas en Santiago* [Tesis, Universidad de Chile]. Repositorio UChile. <https://repositorio.uchile.cl/handle/2250/173212>

Marroquín Flores, D. (2020). *Análisis de movilidad sostenible mediante bicicletas compartidas en Lima Metropolitana* [Trabajo académico, Universidad Peruana de Ciencias Aplicadas]. Repositorio UPC. <https://repositorioacademico.upc.edu.pe/handle/10757/652676>

Gandini, A. (2023). Análisis del uso de bicicletas compartidas y su impacto en la movilidad urbana. *Revista del Instituto de Investigaciones Gino Germani*, 5(2), 45–63. <https://ri.conicet.gov.ar/handle/11336/202149>

Seifert García, R. (2023). *Movilidad urbana sostenible: análisis del sistema de bicicletas compartidas de la ciudad de València* [Tesis, Universitat de València]. Repositorio UV. <https://producciocientifica.uv.es/documentos/68715254e7607a6ed9f1cdf5>

Pans, M., García-Ferrandis, X., & Llopis, R. (2023). Análisis sociodemográfico del uso del sistema de bicicletas compartidas de València. *Retos*, 51, 96843. <https://revistaretos.org/index.php/retos/article/view/96843>

IPSOS & Fifteen. (2023). *Bicicleta compartida en España: cifras clave del estudio de referencia*. Fifteen Mobility. <https://fifteen.eu/es/resources/blog/bicicleta-compartida-en-espana-cifras-clave-del-estudio-de-referencia-de-ipsos>

Velasco-Martínez, J. (2023). *Predicción de la demanda en sistemas de bicicletas compartidas mediante series temporales* [Trabajo Fin de Grado, Universitat Politècnica de Catalunya]. UpCommons. <https://upcommons.upc.edu/entities/publication/c644a748-e8c9-4625-8667-915c4f01cfc8>

Sanmiguel-Rodríguez, A. (2023). Barreras e incentivos de la movilidad en un sistema de bicicletas compartidas en un municipio español. *Revista de Estudios Urbanos y Regionales*, 12(1), 1–20.

[https://www.researchgate.net/publication/369943849 Barreras e incentivos de la movilidad en un sistema de bicicletas compartidas en un municipio espanol](https://www.researchgate.net/publication/369943849_Barreras_e_incentivos_de_la_movilidad_en_un_sistema_de_bicicletas_compartidas_en_un_municipio_espanol)

Anexo: Declaración de uso de inteligencia artificial

De acuerdo con la normativa de la Universidad Francisco de Vitoria para los Trabajos Fin de Grado del curso 2025-26, declaro que me he apoyado en herramientas de Inteligencia Artificial en la elaboración de alguna parte del código y de la memoria.